

A low-angle, upward-looking photograph of several modern skyscrapers reaching towards a clear sky. In the center, an airplane is visible in flight, positioned between the buildings. The image has a slightly desaturated, greyish tone.

기계학습 (2-1): Logistic Classification



임 경 태



CONTENTS

—

①

Logistic Classification

②

Multinomial Classification

③

CONTENTS

—

①

Logistic Classification

②

Multinomial Classification

③

04. Logistic Regression = Logistic Classification (개요)

❑ 점수(정수)가 아닌 Binary(Pass/fail) 분류 문제

- 우리반 학생들의 H 대학 지원 결과가 아래와 같다. 나는 7,3 했는데 합격할 수 있을까?

이름	수학 공부시간	영어 공부시간	합/불
야쓰오	2	3	불합격
오공	4	8	불합격
블리츠	6	2	합격
페이커	8	4	합격

04. Logistic Regression = Logistic Classification (Classification의 예제)

- ❑ Binary Classification (분류) 문제는 무엇인가?
 - ❑ 스팸메일 검출: Yes, No
 - ❑ 영화 추천: 추천, 비추천
 - ❑ 수능 합/불: 합격, 불합격
 - ❑ Where $y=\{0, 1\}$


- ❑ Multinomial Classification (분류) 문제?
 - ❑ 수능 등급 분류: 1등급, 2등급, 3등급, 4등급
 - ❑ 객체 인식: 고양이, 강아지, 사자
 - ❑ 감정 인식: 기쁨, 슬픔, 냉소, 분노
 - ❑ Where $y=\{0, 1, 2, .. n\}$

04. Logistic Classification (개요)

□ 합격 불합격을 어떻게 나눌 수 있을까?

- **로지스틱 회귀**의 목적은 일반적인 회귀 분석의 목표와 동일하게 종속 변수와 독립 변수간의 관계를 구체적인 함수로 나타내어 향후 예측 모델에 사용하는 것이다 (위키)

이름	수학 (x_1) 공부시간	영어 (x_2) 공부시간	합/불 (y)
야쓰오	2	3	불합격
오공	4	8	불합격
블리츠	6	2	합격
페이커	8	4	합격




04. Logistic Classification (개요)

❑ 합격 불합격은 숫자가 아닌데?


- ❑ 숫자로 만들지 뭐! 종속 변수 y 결과의 범위를 $[0,1]$ 로 제한해서 0이면 불합격 1이면 합격으로 만들자!
- ❑ 종속 변수 y 가 이진적이기 때문에 조건부 확률($P(y|x)$)의 분포가 이항 분포를 따른다
- ❑ 종속 변수 y 의 결과는 0과 1, 두 개의 경우만 존재하는데 반해, 단순 선형 회귀를 적용하면 범위 $[0,1]$ 를 벗어나는 결과가 나오기 때문에 오히려 예측의 정확도만 떨어뜨리게 된다. (위키)

이름	수학 (x_1) 공부시간	영어 (x_2) 공부시간	합/불 (y)
야쓰오	2	3	0
오공	4	8	0
블리츠	6	2	1
페이커	8	4	1



04. Logistic Classification (개요)

❑ Linear Regression으로 Classification 을 해볼 수 있지 않을까?



04. Logistic Classification (개요)

□ y값이 0 or 1이 나와야 하는데..

□ 가능한 모든 X에 f(X)가 0 or 1값을 반환하는 함수를 어떻게 찾을 수 있을까?

$$\begin{aligned} H(X)=f(X) &= w_1 * x_1 + w_2 * x_2 + b \\ &= 0 \text{ or } 1 \end{aligned}$$

$$Pr(Y_i = y_i | x_{1,i}, \dots, x_{m,i}) = \begin{cases} p_i & \text{if } y_i = 1 \\ 1 - p_i & \text{if } y_i = 0 \end{cases}$$

이름	수학 (x_1) 공부시간	영어 (x_2) 공부시간	합/불 (y)
야쓰오	2	3	0
오공	4	8	0
블리츠	6	2	1
페이커	8	4	1

04. Logistic Classification (개요)



□ 어떤 값이든 0~1사이로 변경해주는 Sigmoid 함수를 활용하자

$$S(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1}$$

$$H(X)=f(X) = w_1^*x_1 + w_2^*x_2 + b$$



$$S(H(X)) = S(w_1^*x_1 + w_2^*x_2 + b) \\ = 1/(1+e^{-(w_1^*x_1 + w_2^*x_2 + b)})$$




04. Logistic Classification (개요)

□ 어떤 값이든 0~1사이로 변경해주는 Sigmoid 함수를 활용하자

$$S(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1}$$

□ $S(X)$ 값이 0.5보다 크면 1, 작으면 0으로 가정해보자

$$\begin{aligned} S(H(X)) &= S(w_1 * x_1 + w_2 * x_2 + b) \\ &= 1 / (1 + e^{-(w_1 * x_1 + w_2 * x_2 + b)}) \end{aligned}$$



$H(X)$ 값이 음수면
 $S(H(X)) < 0.5$

$H(X)$ 값이 양수면
 $S(H(X)) > 0.5$

즉

$H(X) \geq 0$ 이면 $y=1$ 로 예측

$H(X) < 0$ 이면 $y=0$ 으로 예측


즉

$w_1 * x_1 + w_2 * x_2 + b \geq 0$ 이면 $y=1$ 로 예측

$w_1 * x_1 + w_2 * x_2 + b < 0$ 이면 $y=0$ 으로 예측

04. Logistic Classification (개요)

□ 어떤 값이든 0~1사이로 변경해주는 Sigmoid 함수를 활용하자



즉

$w_1*x_1 + w_2*x_2 + b \geq 0$ 이면 $y=1$ 로 예측

$w_1*x_1 + w_2*x_2 + b < 0$ 이면 $y=0$ 으로 예측

이 말은

$w_1*x_1 + w_2*x_2 + b = 0$ 인 선을 기준으로


- 한쪽은 1

- 다른 한쪽은 0

우리는 이 선을 decision boundary라고 함

04. Logistic Classification (graphical 예제)

□ 데이터 A에 대해 Linear decision boundary를 찾았다고 가정해 보자



w_1, w_2, b_1 을 1, 1, -3로 둔다면

$x_1 + x_2 - 3 \geq 0$ 이면 $y=1$ 로 예측

$x_1 + x_2 - 3 < 0$ 이면 $y=0$ 으로 예측

$x_1 + x_2 \geq 3$ 이면 $y=1$ 로 예측

$x_1 + x_2 < 3$ 이면 $y=0$ 으로 예측

이 말은

$x_1 + x_2 - 3 = 0$ 인 선을 기준으로


- 한쪽은 1

- 다른 한쪽은 0

04. Logistic Classification (graphical 예제)

□ Linear로 분류가 안될 수도 있겠지?

- 실제 예제 Non-linear decision boundary를 보자



w_1, w_2, w_3, w_4, b 을 0, 0, 1, 1, -1로 둔다면

$x_1^2 + x_2^2 - 1 \geq 0$ 이면 $y=1$ 로 예측

$x_1^2 + x_2^2 - 1 < 0$ 이면 $y=0$ 으로 예측

$x_1^2 + x_2^2 \geq 1$ 이면 $y=1$ 로 예측

$x_1^2 + x_2^2 < 1$ 이면 $y=0$ 으로 예측

이 말은

$x_1^2 + x_2^2 - 1 = 0$ 인 원을 기준으로


- 한쪽은 1

- 다른 한쪽은 0


04. Logistic Classification (Cost 함수)

❑ Logistic Classification의 Cost 함수를 MSE로 해볼까?


❑ $H(x) = w_1 * x_1 + w_2 * x_2 + b$




❑ $S(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1}$



❑ MSE $cost(W, b) = \frac{1}{m} \sum_{i=1}^m (H(x^{(i)}) - y^{(i)})^2$



❑ 1차원 함수에 MSE를 하면 Cost값은 2차원 함수로 표현됨, 하지만 1차원 함수에 Sigmoid를 취하면??



Cost 함수에 log를 취해주면?
- 주름이 펴진다 (convex)

04. Logistic Classification (Cost 함수)

□ 그렇다면 Logistic Classification의 Cost 함수는 어떻게 정의하면 될까?

□ Cost함수의 목적에 충실해지자!

- 예측이 틀릴 경우 Cost = 매우 높음
- 예측이 맞을 경우 Cost = 0

if: $y==1$ and $S(x)==1$: #정답과 예측이 일치
return loss=0

if: $y==0$ and $S(x)==0$: #정답과 예측이 일치
return loss=0

if: $y==1$ and $S(x)==0$: #정답과 예측이 불일치
return loss=무한대


if: $y==0$ and $S(x)==1$: #정답과 예측이 불일치
return loss=무한대

04. Logistic Classification (Cost 함수)

□ 그렇다면 Logistic Classification의 Cost 함수는 어떻게 정의하면 될까?

□ Cost함수의 목적에 충실해지자!

- 예측이 틀릴 경우 Cost = 매우 높음
- 예측이 맞을 경우 Cost = 0



$h_\theta(x) = S(H(X))$, where $\theta = \{W, b\}$ 로 간략화 하자!

$$\text{cost}(h_\theta(x), y) = \begin{cases} -\log(h_\theta(x)) & \text{if } y = 1 \\ -\log(1 - h_\theta(x)) & \text{if } y = 0 \end{cases}$$

if: $y=1$ and $S(x)=1$: #정답과 예측이 일치
return loss=0

if: $y=0$ and $S(x)=0$: #정답과 예측이 일치
return loss=0

if: $y=1$ and $S(x)=0$: #정답과 예측이 불일치
return loss=무한대

if: $y=0$ and $S(x)=1$: #정답과 예측이 불일치
return loss=무한대

04. Logistic Classification (Negative Log Likely-hood Cost 함수)

□ $Y = 0, Y = 1$ 두 경우의 손실 함수를 하나로 합쳐보자!

$$\square \text{ Cost}(W, b) = \frac{1}{m} \sum_{i=1}^m -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

$$J(w) = \sum_{i=1}^m y^{(i)} \log P(y = 1) + (1 - y^{(i)}) \log P(y = 0)$$

$$\left. \begin{aligned} \mathbb{P}(y = 1|z) &= \sigma(z) = \frac{1}{1 + e^{-z}} \\ \mathbb{P}(y = 0|z) &= 1 - \sigma(z) = \frac{1}{1 + e^z} \end{aligned} \right\} \mathbb{P}(y|z) = \sigma(z)^y (1 - \sigma(z))^{1-y}$$

04. Logistic Classification (Gradient Decent)

□ Cost값을 기반으로 Gradient Decent 알고리즘을 이용해 최적의 파라미터 W값 을 찾자!

□ $H(x) = w_1 * x_1 + w_2 * x_2 + b$

□ $Cost(W, b) = \frac{1}{m} \sum_{i=1}^m -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$

□ $\underset{W, b}{\text{minimize}} \text{cost}(W, b) \quad W := W - \alpha \frac{\partial}{\partial W} \text{cost}(W)$

□ $\frac{\partial}{\partial \theta} Cost(\theta) = \frac{1}{m} \sum_{i=1}^m (Sh_{\theta}(x^i) - y^i) x^i$

04. Logistic Classification 정리!

□ Logistic Classification을 정리하면!

$$\square H(x) = w_1 * x_1 + w_2 * x_2 + b$$

$$\square S(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1}$$

$$\square S(H(X)) = \frac{1}{1 + e^{-(w_1 * x_1 + w_2 * x_2 + b)}}$$

$$\square Cost(W, b) = \frac{1}{m} \sum_{i=1}^m -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

$$\square \underset{W, b}{\text{minimize}} cost(W, b) \quad W := W - \alpha \frac{\partial}{\partial W} cost(W)$$

04. Logistic Classification 정리!

Appendix: Partial derivative of $J(\theta)$

우선 logistic function의 미분을 구해두자.

$$\begin{aligned}\sigma(x)' &= \left(\frac{1}{1+e^{-x}} \right)' = \frac{-(1+e^{-x})'}{(1+e^{-x})^2} = \frac{-1' - (e^{-x})'}{(1+e^{-x})^2} = \frac{0 - (-x)'(e^{-x})}{(1+e^{-x})^2} = \frac{-(-1)(e^{-x})}{(1+e^{-x})^2} = \frac{e^{-x}}{(1+e^{-x})^2} \\ &= \left(\frac{1}{1+e^{-x}} \right) \left(\frac{e^{-x}}{1+e^{-x}} \right) = \sigma(x) \left(\frac{+1 - 1 + e^{-x}}{1+e^{-x}} \right) = \sigma(x) \left(\frac{1+e^{-x}}{1+e^{-x}} - \frac{1}{1+e^{-x}} \right) = \sigma(x)(1 - \sigma(x))\end{aligned}$$

이제 편미분을 구해보자.

$$\begin{aligned}\frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{-1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))] \\ &= -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \frac{\partial}{\partial \theta_j} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \frac{\partial}{\partial \theta_j} \log(1 - h_{\theta}(x^{(i)})) \right] \\ &= -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)} \frac{\partial}{\partial \theta_j} h_{\theta}(x^{(i)})}{h_{\theta}(x^{(i)})} + \frac{(1 - y^{(i)}) \frac{\partial}{\partial \theta_j} (1 - h_{\theta}(x^{(i)}))}{1 - h_{\theta}(x^{(i)})} \right] \\ &= -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)} \frac{\partial}{\partial \theta_j} \sigma(\theta^T x^{(i)})}{h_{\theta}(x^{(i)})} + \frac{(1 - y^{(i)}) \frac{\partial}{\partial \theta_j} (1 - \sigma(\theta^T x^{(i)}))}{1 - h_{\theta}(x^{(i)})} \right] \\ &= -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)} \sigma(\theta^T x^{(i)}) (1 - \sigma(\theta^T x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{h_{\theta}(x^{(i)})} + \frac{-(1 - y^{(i)}) \sigma(\theta^T x^{(i)}) (1 - \sigma(\theta^T x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{1 - h_{\theta}(x^{(i)})} \right] \\ &= -\frac{1}{m} \sum_{i=1}^m \left[\frac{y^{(i)} h_{\theta}(x^{(i)}) (1 - h_{\theta}(x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{h_{\theta}(x^{(i)})} - \frac{(1 - y^{(i)}) h_{\theta}(x^{(i)}) (1 - h_{\theta}(x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{1 - h_{\theta}(x^{(i)})} \right] \\ &= -\frac{1}{m} \sum_{i=1}^m [y^{(i)} (1 - h_{\theta}(x^{(i)})) x_j^{(i)} - (1 - y^{(i)}) h_{\theta}(x^{(i)}) x_j^{(i)}] \\ &= -\frac{1}{m} \sum_{i=1}^m [y^{(i)} (1 - h_{\theta}(x^{(i)})) - (1 - y^{(i)}) h_{\theta}(x^{(i)})] x_j^{(i)} \\ &= -\frac{1}{m} \sum_{i=1}^m [y^{(i)} - y^{(i)} h_{\theta}(x^{(i)}) - h_{\theta}(x^{(i)}) + y^{(i)} h_{\theta}(x^{(i)})] x_j^{(i)} \\ &= -\frac{1}{m} \sum_{i=1}^m [y^{(i)} - h_{\theta}(x^{(i)})] x_j^{(i)} \\ &= \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] x_j^{(i)}\end{aligned}$$



감사합니다.